

דוח ניתוח

החלטות שנלקחו במהלך בניית סט הנתונים:

- לא להסתמך רק על שם הסרט בחיפוש בוויקיפדיה, אלא לבצע הצלבה של שנת היציאה בתוך הטבלה בצד
- יש מלא דפים בוויקיפדיה שהם "פירושונים" ולכן הטמעתי מנגנון זיהוי אוטומטי לדפים שאינם ערכים
- ויקיפדיה לא תמיד עקבית בפורמט שמות הדפים ולכן בניתי כול מיני פורמטים של URL לפי סדר עדיפות לפני שהיא מאותת לי שהיא לא מצאה
- טקסט מוויקיפדיה מגיע הרבה פעמים עם הערות שאנחנו לא רוצים בנתונים שלנו ולכן עשיתי ניקוי להערות שוליים ולכול מיני סמלים טכניים
- בגלל שאנחנו שולפים הרבה נתונים מוויקיפדיה שמתי (time.sleep) כדי שהקוד לא ייפול
- בניתי פונקציה שבודקת אם תא הוא מספר או טווח ואם הוא טווח שתעשה ממוצע

Columns name	Description	Type	Source
tconst	מזהה ייחודי של הסרט ב-IMDb	String	IMDb
primaryTitle	שם הסרט	String	IMDb
startYear	שנת יציאה לאקרנים	Integer	IMDb
genres	רשימת ז'אנרים	List of Strings	IMDb
lead_actors_ids	רשימה של שמות 5 השחקנים המובילים	List of strings	IMDb
runtimeMinutes	משך הסרט בדקות	Integer	IMDb
averageRating	ממוצע דירוג	Float	IMDb
Language	השפה הראשית בסרט	String	Wikipedia
Country	המדינה בה נוצר הסרט	String	Wikipedia
numVotes	מספר המדרגים	Integer	IMDb
budget	תקציב הפקה במיליוני דולרים (USD)	Float	Wikipedia

Columns name	Description	Type	Source
BoxOffice	הכנסות גלובליות במיליוני דולרים	Float	Wikipedia
plot	תקציר הסרט	String	Wikipedia

אספתי 5000 סרטים, באותיות שקיבלתי היה מעל 11,000 סרטים ככה שלא היה אפשרות להריץ את כולם

מספר הערכים החסרים בכול עמודה :

tconst	0
primaryTitle	0
startYear	0
genres	0
lead_actors_ids	467
runtimeMinutes	0
averageRating	0
Language	2443
Country	2461
numVotes	0
budget	4314
BoxOffice	4104
plot	3054